

Quais Fatores Influenciam os Salários dos Profissionais de Dados no Brasil?

Um Sistema Inteligente para Análise e Predição Salarial

Integrantes:

Antonio Augusto Vieira Lopes Filho
Diego Rodrigo Marinho Silva
Ryan Junio de Oliveira
Vinicius Bigonha Cancela Moraes de Melo Filho

Professores:

Prof. Hugo Bastos de Paula
Prof. Hayala Nepomuceno Curto



Instituição: PUC Minas -
Curso de Ciência de Dados e Inteligência Artificial

Introdução

A área de Ciência de Dados está em forte expansão no Brasil, impulsionada pela transformação digital. Há uma crescente demanda por profissionais qualificados, tornando a análise de remuneração um tema estratégico.

O Problema Central:

Quais características (formação, experiência, tecnologias, localização) afetam de forma mais significativa os salários dos profissionais de dados no Brasil?

Essa é uma dúvida crucial tanto para profissionais planejando suas carreiras quanto para empresas definindo políticas salariais competitivas.

Nossa Proposta:

Desenvolver um sistema inteligente que utiliza aprendizado de máquina para analisar dados do "State of Data - BR 2023" e identificar os principais determinantes salariais no setor.



Resumo do Dataset

State of Data Brazil

- ✓ Registros: +5.200 respostas de profissionais da área de dados.
- ✓ Atributos Principais: Nível de carreira, formação, experiência, cargo, tecnologias (SQL, Python, etc.), ferramentas (Power BI, Tableau, etc.), e dados demográficos (gênero, etnia, localização).

Fontes Auxiliares (Enriquecimento)

- ✓ PIB 2021 (IBGE): Produto Interno Bruto por estado.
- ✓ IDHM 2021 (IPEA): Índice de Desenvolvimento Humano Municipal por estado.



Hipóteses levantadas baseadas na pergunta orientada a dados



- ✓ Hipótese 1: É possível prever a faixa salarial com base em indicadores socioeconômicos (PIB e IDH) do estado onde o profissional atua?
- ✓ Hipótese 2: O setor de atuação e o porte da empresa influenciam o salário? Setores como finanças e grandes empresas pagam mais?
- ✓ Hipótese 3: O domínio de múltiplas linguagens de programação, ferramentas de Cloud e de BI está associado a salários mais altos?
- ✓ Hipótese 3: O domínio de múltiplas linguagens de programação, ferramentas de Cloud e de BI está associado a salários mais altos?

Análise Exploratória de Dados

Principais Insights

Perfil do Profissional:

Idade Média: 32 anos.

Gênero: Predominantemente masculino (75,1%).

Etnia: Maioria se autodeclara Branca (64,5%), seguida por Parda

Insights Salariais:

Geografia: Há uma variação notável na média salarial por UF, correlacionada com indicadores como PIB e IDH.

Gênero e Etnia: Observamos disparidades salariais, com homens e pessoas brancas apresentando médias mais altas.

Experiência é Chave: A média salarial aumenta significativamente conforme o nível de experiência (Júnior, Pleno, Sênior).

Tecnologias e Cargos: Cargos como Arquiteto de Dados e Engenheiro de Dados, e o domínio de certas ferramentas, estão associados a maiores remunerações.



Modelos de Machine Learning utilizados

01 Decision Tree

02 Random Forest

03 K-Nearest Neighbors

04 XGBoost


Decision Tree




Random Forest



KNN



XGBoost



Árvore de Decisão

Por que Árvore de Decisão?


- ✓ Interpretabilidade: Regras visuais e intuitivas.
- ✓ Importância de atributos: Identifica variáveis-chave (feature_importance_).
- ✓ Flexibilidade: Lida com relações não-lineares sem necessidade de normalização.

Particionamento dos Dados

Método: Hold-Out (random_state=42).
75% treino | 25% teste.

Fluxo do Modelo

Divisão dos dados em X (features) e y (target).
Treinamento com DecisionTreeClassifier.
Avaliação no conjunto de teste.



Resultados da Árvore de Decisão

Desempenho Geral

Acurácia: 0.69 (treino) | 0.67 (teste).

Matriz de Confusão

BAIXO

MÉDIO

ALTO

272	99	13
78	242	113
2	75	248

BAIXO MÉDIO ALTO

Relatório de Classificação

Classe	precision	recall	f1-score	support
1	0.77	0.71	0.74	384
2	0.58	0.56	0.57	433
3	0.66	0.76	0.71	325
accuracy			0.67	1142
macro avg	0.67	0.68	0.67	1142
weighted avg	0.67	0.67	0.67	1142

K-Vizinhos Mais Próximos (KNN)

Por que uso do KNN?

- ✓ Simplicidade: Algoritmo intuitivo e eficaz como baseline.
- ✓ Não-paramétrico: Não assume distribuição dos dados.
- ✓ Similaridade local: Classifica com base nos vizinhos mais próximos.

Pré-processamento Crucial

Padronização: StandardScaler aplicado (dados em mesma escala).

Hold-Out:

80% treino | 20% teste (random_state=42).

Validação Cruzada: cv=5 para curvas de aprendizado.

Hiperparâmetro Chave

n_neighbors=20: Número de vizinhos para votação majoritária.


Fluxo do Modelo

Divisão em X (features) e y (target).

Padronização (só com dados de treino!).

Treinamento do KNeighborsClassifier.

Avaliação no teste padronizado.



Resultados K-Vizinhos Mais Próximos (KNN)

Matriz de Confusão



Desempenho Geral

Acurácia: 0.71 (treino) | 0.67 (teste).

Relatório de Classificação

Classe	precision	recall	f1-score	support
1	0.78	0.72	0.75	310
2	0.58	0.58	0.58	348
3	0.66	0.72	0.69	255
accuracy			0.67	913
macro avg	0.67	0.67	0.67	913
weighted avg	0.67	0.67	0.67	913

Comparação dos resultados Árvore de Decisão e KNN

- Desempenho similar: Ambos os modelos alcançaram acurácia de ~67% no teste.
- Generalização adequada: Diferença $\leq 2\%$ entre treino e teste, indicando baixo overfitting.
- Pontos fortes distintos:
 - Árvore de Decisão: Melhor para identificar altos salários (Recall 76%).
 - KNN: Ligeira vantagem para salários baixos (*F1-Score* 0.75 vs 0.74).
- Dificuldade comum: Classificação de salários médios (pior desempenho em ambos).



Conclusão

Fatores Analisados

Experiência | Tecnologias | Escolaridade | Localização (IDH/PIB) |

Principais Determinantes Salariais

- ✓ Experiência profissional
- ✓ Domínio de tecnologias em alta demanda (Python, Cloud, ML)
- ✓ Localização geográfica

Vantagens do Sistema

"Sistema valioso, mas dependente da qualidade dos dados e da consideração de aspectos qualitativos."

Melhorias Propostas

- + Fontes de dados: LinkedIn, portais de emprego
- + Variáveis: Certificações, idiomas, soft skills
- Predição personalizada (ferramenta interativa)
- Análise temporal (evolução salarial)

